



目录可在ScienceDirect查阅

模式识别

期刊主页: www.elsevier.com/locate/pr

FINet: 基于字体模仿网络的汉字书写轨迹重建

朱远平*, 李胜楠, 王辉, 魏飞龙

天津师范大学计算机与信息工程学院, 中国天津市西青区滨水西路393号, 邮编: 300387

文章 信息

数据集链接: <http://www.nlpr.ia.ac.cn/databases/handwriting/Download.html>

关键词:

手写轨迹重建 空间编码器

时间解码器笔画特征网

络

汉字手写识别

摘要

从中文手写图像中恢复在线手写轨迹仍是难题, 因汉字笔画繁多、结构复杂且书写风格各异。为解决此问题, 本文提出一种名为字体模仿网络的汉字手写轨迹重建方法。字体模仿网络整合了两个网络: 空间编码器采用HRNet对离线图像中每个位置的空间关联信息进行编码; 时间解码器由多层感知器和循环神经网络构成。笔画特征网络通过热力图形式聚焦笔画路径, 辅助预测下一书写点。实验在CASIA-OLHWDB1.1数据集上进行, 采用动态时间规整 (DTW)、局部动态时间规整 (LDTW)、均方根误差 (RMSE) 及字符识别准确率作为评估指标。实验结果表明, 本方法显著优于现有最先进方案, 且通过书写轨迹重建有效提升了离线字符的识别精度。

1. 引言

过去二十年来, 手写文本分析[1]与识别[2]一直是研究者广泛关注的领域。当前研究中, 针对英数字符符号的在线手写轨迹恢复[3]已有诸多研究, 但多数聚焦于单笔画字符, 而针对多笔画汉字手写轨迹重建的研究则较为匮乏。汉字手写轨迹重建任务仍面临诸多挑战, 包括笔画结构复杂、数据采集困难及书写序列较长等问题。汉字手写重建技术可广泛应用于汉字手写识别[4]、笔迹鉴定[5]、书写风格建模[6]、笔迹分析[7]及合成[8]等领域。

基于采集技术, 手写信息主要通过离线与在线两种采集方式获取。离线方法中, 图像扫描设备捕获的静态二维图像是唯一可用信息, 无法获取时间信息[9]。在线方法则可通过触控笔、绘图板等专用输入设备额外采集手写动态信息, 包括书写速度、压力、倾斜角度等。笔尖轨迹的坐标信息可被利用。因此离线字符识别与在线字符识别的准确度存在一定差距[10,11], 这种差异源于离线字符特征信息的缺失[12], 故

通过重建在线手写特征来提升离线字符识别准确度在理论上是可行的[13]

。

基于人类书写汉字的特性, 当人们书写不熟悉的汉字时, 会根据对汉字结构的认知提取出某些常见笔画、笔画顺序及笔画间的关系, 这有助于我们尝试学习汉字的正确书写方式, 即使对该字不熟悉[14,15]。基于这些特征, 我们将手写重建任务描述为空间信息向时间信息的模态转换问题, 即预测每个手写点在不同时间图像上的响应概率。本研究将基于空间编码器与时间解码器架构的网络整合至字体模仿网络中: 编码器部分采用HRNet作为特征提取模型, 其结构的多尺度特性更倾向于挖掘深层空间信息, 用于捕捉图像不同层级的细节与结构特征; 解码器由多层感知器与门控循环单元构成, 主要基于深度空间信息挖掘特征点间关联性, 并结合前一刻的书写状态信息。为增强路径信息, 解码环节引入笔画特征网络辅助处理。

* 通讯地址: 中国天津市西青区滨水西路393号

电子邮箱: zhuyuanping@tjnu.edu.cn (朱燕)<https://doi.org/10.1016/j.patcog.2024.110949>

收稿日期: 2023年11月17日; 修订稿收稿日期: 2024年8月26日; 接受日期: 2024年8月26日

在线发布日期: 2024年8月29日

0031-3203/© 2024 Elsevier Ltd. 保留所有权利, 包括文本和数据挖掘、人工智能训练及类似技术的相关权利。

表1
手写重建的相关研究工作。

方法	参考文献	评估指标	数据集	对象
基于规则的方法	[16]	角度计算	一万个手写字符集	词语与字母
基于规则的方法	[17]	正确轨迹恢复率	由韩国科学技术院人工智能实验室收集的手写汉字	汉字
基于规则的方法	[18]	正确轨迹恢复率	由20位书写者提供的200幅中文手写字符图像集	汉字
基于规则的方法	[19]	偏差角与分布函数	UWM手写签名数据集	签名
基于规则的方法	[20]	信噪比、均方根误差与动态时间规整	SigComp2009、SUSIG视觉和SVCTask2	签名
基于规则的方法	[21]	检测到的笔画点计数	2004年签名验证竞赛数据集	签名
基于规则的方法	[22]	准确率	俄语扫描手写单词	单词与字母
基于学习的方法	[23]	正确轨迹恢复率	CASIA-OLHWDB1.1与ICDAR2013在线竞赛HCCR竞赛数据库	特征
基于学习的方法	[24]	平均正确轨迹恢复率	CASIA-OLHWDB1.0-1.2	字符与数字
基于学习的方法	[25]	视觉验证与准确度	Nakayosi_t-98-09 与 Kuchibue_d-96-02	字符
基于学习的方法	[26]	准确率	LIPI工具包数据集 (泰米尔语、泰卢固语和德瓦纳加里字符)	字符
基于学习的方法	[27]	准确率	LMCA与IRONOFF	字符与数字
基于学习的方法	[28]	正确轨迹恢复率	CASIA-OLHWDB 1.1 和 UNIPEN	字符与数字
基于学习的方法	[29]	正确终点选择率、分支点解析率、完整轨迹恢复率	CASIA-OLHWDB 1.1 与 UNIPEN	字符与数字
基于学习的方法	[30]	精确率、召回率、F值与准确率 (起始点与HTR)	CASIA-OLHWDB1.1与ICDAR-2013在线HCCR竞赛数据库	字符
基于学习的方法	[31]	LPIS、LDTW、DTW 和 RMSE	CASIA-OLHWDB1.0-1.2、Nakayosi_t-98-09 以及 Kuchibue_d-96-02 和 印度语 (泰米尔语)	字符

生成稳定的书写信息。采用JSDiv损失约束热图的概率分布，最终通过DTW、LDTW、RMSE及字符识别准确率评估重建的在线书写效果。

本文其余部分组织结构如下：第2节概述了基于传统学习和深度学习方法的在线手写重建相关研究；第3节详细描述了本文提出的字体模仿网络模型；第4节通过验证流程对所提方法进行训练与评估；第5节讨论结论与未来工作。

2. 相关工作

基于静态手写字符重建动态手写体主要包含两种方法：基于规则设计的传统方法与基于学习的方法（详见表1），该表详细列举了主要方法、数据集、评估指标及其研究对象。

传统汉字手写重建方法包括图搜索、模板匹配和书写规则。图模型基于最小能量成本准则寻找成本最小的路径。[16]对离线汉字进行骨架化处理，再利用启发式规则在模糊区域中选择特定路径。基于模板匹配的方法[17]需要构建笔画模板库，通过将输入图像与模板进行比对来重建手写内容。[18]提出了一种重建多笔画汉字在线书写的方法。为避免汉字模板数量庞大，将汉字划分为三部分：部件、子部件和笔画。通过四条启发式规则计算子部件间的关联关系。该方法计算最优路径过程过于复杂。

在匹配过程中。基于书写规则的方法[19]利用字符的结构特征来表达笔画间的关系，进而通过规则恢复其顺序。其缺点在于无法适应书写风格的变化，也无法利用断笔处理文本。此类方法通常仅适用于单字符重建，无法处理手写文本串的重建。[20]提出通过点分类、局部检测与全局重建三步法，对细化后的静态轨迹进行顺序恢复，该方法能有效解析簇点并选择笔尖落笔的执行顺序。[21]的方法从灰度图像中提取控制点，确定其顺序并分配至笔画。[22]采用图像骨架表示法进行手写重建，将图结构分解为基本单元，为每个单元估计笔尖运动方向，最终轨迹由这些单元轨迹组合而成。

尽管基于深度学习的方法[23]在许多任务上取得了更优结果，但部分研究者采用编码器-解码器网络生成在线手写体。[24]通过对图像进行一系列预处理（如二值化、骨架化等），将手写重建问题转化为预测图像值与尺寸的关系，使字符粗细度转化为单个像素，随后网络预测每个像素的值，再根据尺寸值决定其顺序。其缺陷同样显著：直接以像素值回归作为排序依据存在不稳定性，需通过后处理消除此类波动。[25]提出基于深度神经网络的方法，结合编码器-解码器模型、注意力机制及高斯混合模型，实现从离线日文手写图像中恢复动态在线轨迹。该方法提升了

通过将注意力层集成到编码器网络中，在一定程度上提升了多笔画日文汉字的在线轨迹重建质量。该方法能提取局部特征，并保持构成每个汉字图案的所有笔画之间的二维空间关系。采用编码器-解码器网络[26]，在通过卷积神经网络提取图像特征后，直接对笔画点进行回归。此类方法利用了循环神经网络（RNN）的时间编码与解码能力，具备一定时间信息捕捉能力。然而直接回归方法的最大缺陷在于：空间信息融入一维信息必然导致信息丢失，尤其缺乏空间表达能力。这迫使作者在后处理阶段必须将点位校正至最近黑像素点作为书写点输入的下一时刻。因此该方法无法适应复杂轨迹的重建。在[27]中，研究者基于Seq2Seq模型的恢复框架，采用VGG-LSTM作为编码器提取特征，并以BLSTM模型作为解码器生成时间坐标，通过重采样操作构建笔速曲线，在时间维度上取得了一定程度的改进。

然而，该方法不适用于汉字等复杂笔画的手写重建任务。另有研究采用回归卷积神经网络从图像中提取特征，最终由网络预测每个像素的顺序关系排列。基于回归卷积神经网络的算法[28]可预测下笔点位置概率，其迭代框架利用预测输出向量生成笔迹运动序列。该方法能有效学习不同文字的共性书写模式，同一作者团队在[29]中进一步优化了该架构。该方法采用两个回归卷积神经网络模型生成两组对应的笔尖运动热力图，再通过专属框架分析热力图以估算笔尖轨迹。该方法可同时应用于英汉手写重建任务：SPNet[30]用于在SkeNet和AZNet生成的笔画段中定位起始点，Conv-Ptr-Net则用于测量顺序矩阵。最终笔迹轨迹通过启发式搜索确定最佳对齐方案。[31]提出双流解析编码器与全局追踪解码器，以解决复杂字形与长轨迹场景下的识别难题。上述深度学习方法通常通过编码器-解码器网络结合卷积神经网络（CNN）与循环神经网络（RNN）生成手写序列。然而后者因汉字本身复杂的字形结构而表现不稳定。我们认为其根源在于汉字复杂的空间信息难以编码为一维向量，同样地，一维向量也难以表达多个连续空间点的二维信息，导致解码过程中生成的书写点出现不稳定现象。

3. 方法论

本节将详细阐述我们提出的方法如何实现从离线字符图像重建在线手写文本。字符图像中通常隐含着手写点之间的关联关系，当书写者重写文本时，这些手写点之间的序列关系便能被有效挖掘。因此，从离线字符图像中重建手写点序列关系是可行的。难点在于检测手写点以及分析手写点间的序列关系。本文将手写重建网络描述为类似于手写检测与顺序恢复的网络，该网络通过...

表2

空间编码器的参数。

阶段	[输入通道数, 输出通道数, 缩放因子]
Conv1	[1,64,1/2]
Conv2	[64,64,1/4]
瓶颈层	[64,128,1/4]
基础块1	[128,128,1/4]
	[128,256,1/8]
基本块2	[128,128,1/4]
	[256,256,1/8]
	[256,512,1/16]
基本块3	[128,128,1/4]
	[256,256,1/8]
	[512,512,1/16]
	[512,1024,1/32]
	[128,128,1/4]
基础块4	[256,256,1/8]
	[512,512,1/16]
基本块4	[1024,1024,1/32]

网络架构被整合到字体模仿网络中，其总体框架如图1所示。网络输入为静态字符图像，通过特征提取生成特征图。解码网络结合GRU生成的时序特征、编码器的空间特征及笔画特征，输出对应热力图，该热力图同时用于当前时刻状态预测与下一时刻书写点预测。通过此机制预测当前书写点，并重复该操作直至所有书写点预测完成。

3.1. 空间编码器

编码器主要负责从静态字符图像中提取空间关联信息供后续网络使用。我们采用HRNet作为空间编码器网络的主干结构，其多分支架构可同时处理不同分辨率的信息，从而在不同尺度上呈现每个笔画的细节与轨迹，用于构建更丰富的空间关系模型。

我们使用的HRNet具体参数如表2所示，该网络采用三个下采样模块将特征图尺寸缩减至原尺寸的八分之一，同时进行并行特征图计算与特征融合。每个模块均包含ResNet结构以确保特征提取能力和网络稳定性。在放大特征图尺寸的过程中，我们采用反卷积替代上采样，两者在计算时间上相当，但反卷积在梯度传递方面更为清晰。人体关键点检测实验[32]也证实反卷积优于上采样。图像为

通过空间编码器编码为张量 G ，其尺寸为 $d \times H \times W$ 。网络进行编码后，维度 d 的值为128，而维度 H 和 W 均为64。

3.2. 笔画特征网络

仅用一维向量难以表示多个连续空间点的二维信息，这导致解码过程中笔画点生成不稳定，因此需要以其他形式存储二维空间信息，使循环神经网络（RNN）在笔画点上下文中摆脱对关联挖掘的依赖。故本文参照[16]，设计了适用于笔画特征提取的笔画特征网络。该笔画特征网络旨在从64×64二值图像中提取局部特征，其结构包含：笔画特征网络用于从64×64二值图像中提取局部特征。该网络包含




图1. 手写重建整体流程。

七个卷积层，卷积核尺寸为 3×3 ，特征图数量分别为32、64、64、128、128、256、256。在

在第二、第四及最后的卷积层之后，应用批量归一化层（BatchNorm）以提升学习速度，同时采用漏极整流线性单元（ReLU）作为激活函数

函数。笔画特征网络的输入为点阵图

所有先前时刻的手写点，然后特征

提取的特征作为解码器的输入之一，用于预测

下一个手写点。最终计算如式(1)至(4)所示。

$$n, m = \text{argmax} (p_{t-1} - p, I, C, F) \in R^{H \times W} \quad (1)$$

$$I_{nm} = 1 \quad (2)$$

$$C_t = C_{t-1} + I_{nm} \quad (3)$$

$$F_t = SF(C_t) \quad (4)$$

笔画点以序列形式表示，以便将这些坐标序列映射到二维图像中

在该空间中，我们定义矩阵 I ，其中 p_{t-1} 是时间步 $t-1$ 处的概率张量， n 和 m 分别是当前时间步中代表最大概率点的水平与垂直坐标。

按时间步序列，将各时刻的 I_{nm} 依次累加形成笔迹轨迹 C_t ，从而生成包含所有预测笔画点的图像。 $SF(\cdot)$ 为笔画特征网络模块。 F_t 表示笔画特征。该图像输入SFNet提取笔画特征，作为分支

用于预测下一个时间步的手写点。

3.3. 时间解码器

由于从图像重建手写序列前后模态不同，其底层渲染机制

机制有所不同，虽然同样是图像到图像的转换，但需要生成热力图且需多次生成，同一模态内的解码器无法实现此操作。因此我们采用GRU与MLP组合的形式构建解码器，其中GRU主要负责挖掘时间信息，MLP则专注于融合时空信息以输出热力图。

时间解码器网络预测不同时间步长下最大概率点的绝对位置，其不通过全连接层直接输出坐标，而是输出各区域的概率值。MLP作为多层感知器由多个全连接层构成，作为输出层的

时域解码器网络通过融合空间特征、前一时间步GRU的隐藏状态及当前时间步的笔画特征，预测当前时间步手写点的最大概率位置，具体如式(6)至(7)所示。

$$ev^T \tanh(WH + UG + UF) \quad (5)$$

$$p_t = \frac{\exp(e_t)}{\sum_{i=0}^L \exp(e_i)}, L = H \times W \quad (6)$$

$$X_t = G[\max(p)] \quad (7)$$

其中 v_a 、 W_a 、 U_a 、 U_f 分别为权重矩阵， H_{t-1} 为隐藏状态， G 是全局空间特征， F_t 是所有先前时刻的笔画特征。我们选取最可能点 X_t 以强化点间关联。由于GRU的输入是

通过将前一时刻的热力图与空间信息结合生成的单维向量，GRU的输入维度需与空间编码特征的维度（即128维）相匹配。MLP需要整合三类可能存在冗余信息的特征，因此在融合前将三类特征信息映射到128维向量。最终MLP将各空间信息点的特征与笔画特征、时间特征融合，生成目标热力图。GRU的隐藏状态计算公式见式(8)至(11)。

$$r_t = \Sigma(W_{rh}H_{t-1} + W_{rx}X_t + b_r) \quad (8)$$

$$z_t = \Sigma(W_{zh}H_{t-1} + W_{zx}X_t + b_z) \quad (9)$$

$$H_t = \tanh(W_h(H_{t-1} \otimes r_t) + W_xX_t + b_h) \quad (10)$$

$$H_t = (1 - z_t) \otimes H_{t-1} + z_t \otimes H_t \quad (11)$$

其中 $\Sigma(\cdot)$ 为sigmoid函数， z_t 、 r_t 、 H_t 分别对应更新门、重置门及候选状态。

3.4. 损失函数

总体而言，热图的损失函数主要由MSE损失构成，这种形式的损失函数能够满足将热图作为最终输出（而非概率向量）作为注意力机制的方法。相反，我们需要将热图与空间特征图结合以生成GRU的输入向量，因此需要确保整张图的概率之和为1以形成注意力机制。在通过

softmax 确保了输出中每个概率点的损失关系。但同时, 基于 softmax 的交叉熵损失仅能保证特征图中某一点的概率值被最大化, 这在多分类任务中具有适用性。本方法中, 热力图既作为最终输出又作为中间特征, 需确保目标关键点区域均具有一定概率, 使组合后的GRU输入向量能包含更多区域信息并提升其稳定性。因此最终采用JSDiv散度作为模型损失函数, 其表达式如式(12)至(14)所示。

$$KL(P \| Q) = \sum_x p(x) \log \frac{p(x)}{q(x)} \quad (12)$$

$$M = \frac{1}{2}(P + Q) \quad (13)$$

$$l_{JSD} = \frac{1}{2}KL(P \| M) + \frac{1}{2}KL(Q \| M) \quad (14)$$

其中 P 和 Q 分别对应预测热力图与真实值。 M 是两个概率在重叠区域的平均分布, 我们设计了两个规则 (式 (18)和式(19))。该操作不会移除关键点, 也不影响字符结构, 仅改变模型的学习过程。

分布 P 和 Q , 更准确地衡量热力图与真实值之间的差异。

在热力图转为坐标的过程中, 坐标系

梯度通常以argmax形式计算, 但在

中间项无法计算且会导致坐标量化。因此我们添加通道输出偏移量以缓解

量化造成的误差, 同时提高模型的稳定性。因此选择MSELoss作为偏移量的输出, 具体损失函数如式(15)所示。

$$l_{MSE} = \frac{1}{n} \sum_i (p_i - q_i)^2 \quad (15)$$

最终损失函数如式(16)所示。由于交叉熵损失的基数远大于均方误差, 需引入系数 α 平衡两者损失, 其中 α 取值为0.3。

$$l = \alpha l_{JSD} + (1 - \alpha) l_{MSE} \quad (16)$$

4. 实验

在本章中, 针对CASIA-OLHWDB1.1[33]数据集开展了多组实验, 以验证所提模型在笔迹重建任务中的有效性。

4.1. 数据集处理

本实验采用CASIA-OLHWDB1.1数据集, 包含3755类GB2312-80一级汉字及


171类字母符号, 由300名书写者使用Anoto笔书写采集。每个汉字书写于独立页面, 并记录笔画轨迹的坐标与状态。我们对CASIA-OLHWDB1.1中的全部汉字进行实验, 每个汉字包含240个训练样本和60个测试样本。

4.1.1. 在线字符生成

相较于保存为静态图像的离线手写字符, 在线手写字符通过连续书写点序列保留了书写时更丰富的动态信息。我们将该信息表示为式(17)中的可变量序列。

$$[x_1, y_1, s_1], [x_2, y_2, s_2], \dots, [x_n, y_n, s_n] \quad (17)$$

在在线数据采集过程中, 原始在线数据集并非按固定尺寸采集, 而是以绝对坐标形式获取。为规范不同坐标系的在线模式, 需动态缩放在线字符模式至[0,64]区间。由于点密度较高, 缩放后点可能相互重叠。为过滤掉



冗余点的平均分布, 我们设计了两个规则, 即式(18)和式(19)。该操作不会移除关键点, 也不会影响字符结构, 仅影响模型的学习过程。

$$\sqrt{(x_i - x_{i-1})^2 + (y_i - y_{i-1})^2} \leq T \quad (18)$$

$$\frac{\Delta x_i(-\Delta x_i + \Delta y_i) \Delta y_i}{(\Delta x_{i-1}^2 + \Delta y_{i-1}^2) \cdot (\Delta x_i^2 + \Delta y_i^2)} \leq C \quad (19)$$

其中 x_i 和 y_i 分别表示水平和垂直坐标, s_i

表示第 i 个点的状态。 $s_i = 0$ 表示起点,

$s_i = 1$ 表示中点, $s_i = 2$ 表示终点。此处将 T 设为图像高度的 0.05 倍以过滤点

当前点与前一点之间距离过近的情况, 且 C 被设置为-0.95, 用于判断当前点与前一点之间角度的余弦值, 以及当前点与

相邻笔画点之间夹角接近180度的点。为避免起止点被过滤, 仅当满足xml-ph-0000@deepl.internal(-1) = xml-ph-0001@deepl.internal = xml-ph-0002@deepl时才执行过滤操作。

仅当 $s_{i-1} = s_i = s_{i+1}$ 时才执行。冗余点如

如图2所示。

4.1.2. 离线字符生成

由于目前尚无同时收集在线与离线模式的中文手写数据集。为训练字体模仿网络模型, 并确保手写标签与离线图像对应, 我们利用前述预处理后的字符动态序列生成对应的离线图像。首先将预处理后的手写点序列坐标映射到64×64的网格, 进而生成64×64尺寸的离线字符图像。为模拟真实场景中的字符图像, 训练过程中笔画粗细随机在1至3之间变化, 测试阶段统一设定为2。

4.2. 训练细节

本研究实验环境如下: Ubuntu 18.04操作系统, Python 3.6.2版本, Pytorch 1.2.0版本, 以及NVIDIA GTX1080Ti GPU。在训练FINet时, 初始学习率设定为0.001, 并在前三十个训练周期保持恒定, 此后每十个训练周期学习率递减10%。最后一个训练周期恢复初始学习率。经过12,000次迭代后, FINet训练过程的损失曲线如图3所示, 模型损失最终收敛。




图3. FINet的训练损失曲线。

4.3. 与前沿方法的对比

在本节中，我们将通过FINet恢复的轨迹与现有最先进方法进行比较，包括Pen-Trace[22]、SPNet[30]、Kanji-Net[25]和Pen-Net[31]。由于官方公开实现版本稀少，我们重新实现了上述模型。在相同数据集上训练后，我们报告了4.4节中结果的平均值。从可视化效果和定量指标来看，我们的FINet相较于多项最先进方法展现出卓越性能。

可视化结果如图4所示，FINet重建的手写序列生成的字符图像仍保持与原始图像相同的书写结构特征，如拐点、终点及笔迹密度。Pen-Trace[22]、SPNet[30]、Kanji-Net[25]和Pen-Net[31]能恢复简体汉字的手写轨迹。然而对于复杂汉字，其恢复效果欠佳：Pen-Trace[22]随笔画数量增加可能丢失部分重建内容；SPNet[30]在复杂笔画的邻接或重叠区域可能产生错误预测——将同向笔画预测为平滑线段，导致细节缺失。Kanji-Net[25]在预测序列延长时，重建手写轨迹会逐渐偏离预期轨迹，主要表现为轨迹的渐变形或不连贯，导致生成的手写内容难以辨认或不符合人类正常书写模式。Pen-Net[31]通过聚焦上下文信息可在一定程度上缓解长轨迹漂移问题，但对笔画字形结构等细节信息的恢复效果较差。相比之下，我们的FINet能为简单与复杂汉字提供精准可靠的重建，既保留笔画关键细节，又生成更稳定的结果。为更直观展示本方法的手写生成序列，图5呈现了预测的手写点位及笔画顺序，不同颜色代表不同笔画。为更生动展示基于FINet的手写动态生成过程，中文汉字及动画图形示例详见链接<https://github.com/369-SN/FINet>。

4.3.1. 轨迹恢复评估

我们计算了手写重建结果与目标序列之间的动态时间规整（DTW）、长度无关动态时间规整（LDTW）及均方根误差（RMSE）。其中采用评估指标LDTW（长度无关动态时间规整）

表3

不同笔画分布下的轨迹恢复评估。

笔画分布	1-5	5-10	10-15	15-20	20-25
比例	9%	51%	34%	5%	1%
底特律	216.9	220.1	229.7	232.5	240.4
LDTW	1.64	1.75	2.27	2.31	2.56
均方根误差	11.63	11.85	12.47	12.63	13.21

表4

基于最先进方法的轨迹恢复评估。

模型 [参考文献]	数据集	动态时间规整	LDTW	均方根误差
笔迹追踪 [22]	CASIA-OLHWDB1.1	465.3	5.61	16.57
SPNet [30]	CASIA-OLHWDB1.1	392.7	5.45	16.01
汉字网络词典 [25]	CASIA-OLHWDB1.1	442.7	5.51	15.43
笔形网络 [31]	CASIA-OLHWDB1.1	233.8	3.11	14.39
FINet (不含S F Net)	CASIA-OLHWDB1.1	410.8	4.76	16.35
FINet (含SFNet)	CASIA-OLHWDB1.1	224.6	1.78	11.85

由[34]提出。LDTW对汉字轨迹点的变化具有更强的鲁棒性。


汉字的复杂度主要由笔画数决定，即对应的笔画数量。例如图4中各汉字的笔画数分别为3、5、7、7、8和16，其复杂度呈递增趋势。不同笔画数的占比及其恢复效果如表3所示，不同笔画数的恢复效果存在差异，这符合预期。因为笔画数越多汉字结构越复杂，恢复难度也越大。该实验证明了本方法在复杂手写字恢复方面具有优越性能。

如表4所示，我们的方法在轨迹恢复评估指标（DTW、LDTW、RMSE）上分别实现了3.9%、42.8%和17.7%的提升，这表明我们的FINet相较于现有最先进方法具有令人满意且卓越的性能。为进一步验证所提出的笔画特征有效性，我们针对该特征进行了消融实验。笔画特征的加入有助于解码器更好地理解字符的书写特性，并能更真实地模拟实际书写过程，从而提升了上述指标的效果。可视化结果如图6所示，解码器虽具备生成手写点序列的充分信息，但因缺乏笔画特征，生成的点序列无法匹配手写字符图像的像素，且可能与同类字符的特征相似。因此，笔画特征与网络结构对适应真实字符图像及正确重建手写字符至关重要。

4.3.2. 字符识别评估

为评估重建手写体的质量，我们构建了一个结合离线与在线识别器的复合识别系统[35,36]。本研究采用的离线识别模型为HCCR-GoogleNet[37]，其训练数据源于本研究训练数据转换而成的离线图像。在线识别模型则采用RNN:NET6-subseq30[38]，该模型通过预处理后的在线样本进行训练。

首先，本文通过评估重建手写体的在线识别准确率，间接衡量了每种手写重建方法的质量。针对每种方法重建的手写序列，从测试集随机抽取10,000个样本进行在线识别器测试。如表5所示，其准确率差异直观表明，相较于其他方法，我们的FINet在手写重建领域具有更优异的性能。



/图4. OLHWDB数据集中离线字符的恢复轨迹示例。




图5. 代表笔顺的示例字符。（关于本图例中颜色标记的解释，请参阅本文的网络版本。

)

效性

通过结合在线与离线识别结果，评估重建在线手写数据对离线识别的有

Y. Zhu 等
；权重公式如式(20)所示。

$$A_{comb} = \gamma A_{off} + (1 - \gamma) A_{on} \quad (20)$$

其中 A_{off} 和 A_{on} 分别表示离线和在线识别模型的识别分数，超参数 γ 是离线和在线识别模型的分类置信度权重。当 $\gamma=1.0$ 时，表示仅使用离线识别器。




图7. 基于识别模型的笔迹识别准确率。




图8. 未见汉字的重建效果。

表5

CASIA-OLHWDB1.1在线识别结果。

模型 [参考文献]	数据集	准确率
笔迹追踪 [22]	CASIA-OLHWDB1.1	94.70%
SPNet [30]	CASIA-OLHWDB1.1	97.02%
Kanji-Net [25]	CASIA-OLHWDB1.1	95.36%
笔形网络 [31]	CASIA-OLHWDB1.1	96.92%
FINet (本公司)	CASIA-OLHWDB1.1	97.24%
原始轨迹	CASIA-OLHWDB1.1	97.97%

如图7所示，发现识别准确率在

γ FINet和Pen-Net[31]的 γ 值为0.6，而SPNet[30]的 值为0.7。由于重建的在线轨迹与原始轨迹存在差异，其对离线图像识别的贡献程度有限。然而，该研究验证了优质在线轨迹对离线字符识别的有效性，并成功利用重建的手写轨迹提升了离线字符识别率。另一方面，识别结果也验证了FINet的手写重建效果优于其他方法。




图9. 不同笔画粗细的离线字符重建结果（自上而下：离线字符、重建手写体与真实标签）。




图10. 手写重建的错误样本。（关于本图例中颜色标记的解释，请参阅本文网络版。）

4.4. 未见汉字实验

本节实验重点验证FINet是否在重建手写体方面具备更强的学习能力。实验训练过程仅使用上述训练数据集中部分字符类别，而训练数据未包含的300类字符则被称为未见字符。重建效果如图8所示。尽管关键点存在少量瑕疵，未见汉字的重建效果与其他字符并无显著差异。这仍验证了本方法具备重建未见汉字的能力，而非简单记忆特定字符。正如人类书写未见字符时，能凭借结构认知正确书写字符。最终该实验证明，面对未见字符时，FINet展现出卓越的实用性与重建效能。

4.5. 笔画粗细分析

离线字符的笔画粗细可能影响重建效果，我们通过实验验证了不同笔画粗细对重建结果的影响。在训练集中，笔画粗细随机变化为1、2和3。如图9所示，当测试集的笔画宽度与训练集一致时，重建效果显著，如(a)、(b)和(c)所示。该结果证明本方法适用于具有一定粗糙度的样本。当笔画粗细增加至(d)和(e)时，简单字符的重建效果良好，但复杂字符效果下降。这表明本方法对其他粗细字符具有鲁棒性，但若粗细超出样本自适应范围则存在局限性，可通过增加不同笔画粗细样本数量加以改善。

4.6. 错误分析

图10列举了若干重建手写体的典型错误样本，其中蓝色虚线圈出的部分标注了具体错误细节。左侧为离线图像，右侧为重建后的在线手写体。(a)中笔画过于密集，导致该区域出现多次重复行走。(b)因误判字符终点状态，导致末笔被重复书写。(c)笔画终点特征识别错误，导致笔画部分被重复添加。如图所示的重建错误(d)由线段重叠引起，网络误判了分支路径。我们将所有这些情况归因于字符复杂度的增加，这最终导致整个手写汉字的重建效果下降——因为中间帧中生成的错误手写点，导致后续选取的特征位置出现偏差。

5. 结论

本文提出一种基于字体模仿网络（FINet）的汉字笔迹轨迹重建新方法。该网络将空间编码网络与时间解码网络融合，协同构建出稳健可靠的笔迹重建框架。笔画特征被引入解码阶段，显著增强了路径信息的提取与保留能力，提升了轨迹重建精度。此外，采用JSDiv散点图作为损失函数，既确保生成的热力图概率分布更集中，又使中间注意力层的计算更高效。实验验证了该方法能有效解决重建过程中的不稳定性问题。

本文解决了以往手写重建方法面临的挑战，为汉字手写重建提供了稳定可靠的解决方案。此外，通过为重建的手写轨迹提供丰富的上下文信息和动态书写特征，进一步验证了其能增强离线字符识别能力，从而提升识别系统的准确性和适应性。

从误差分析可知，密集笔画与不规则笔顺会对笔迹轨迹预测产生负面影响，这些书写细节将成为未来研究重点。此外，探索替代解码器有助于处理大规模复杂字符的长程依赖关系——例如Transformer模型能高效捕捉处理长程依赖。最后，将手写重建对象从单字扩展至字符串，是另一个富有挑战性的研究方向。

CRediT作者贡献声明

朱远平：撰写——审阅与编辑、监督、资源、项目管理、方法论、资金获取、概念化。**李胜楠**：撰写——初稿、可视化、验证、软件、方法论、调查、数据整理、概念化。**王辉**：撰写——审阅与编辑、验证、软件、形式分析、数据整理。**魏伟龙**：撰写——初稿、软件、方法学、调查、数据整理。

利益冲突声明

作者声明，他们没有已知的可能影响本文所报告工作的财务利益冲突或个人关系。

数据可用性

本研究分析的数据集可通过以下链接获取：
<http://www.nlpr.ia.ac.cn/databases/handwriting/Download.html>。

致谢

本研究得到天津市自然科学基金（项目编号：18JCYBJC85000）的支持。

参考文献

- [1] T. Archibald, M. Poggemann, A. Chan, T. Martinez, Trace: 基于可微方法的离线手写文本线级笔画重建, 载于: 《文档分析与识别——ICDAR 2021: 第16届国际会议论文集》第III卷16, 瑞士洛桑, 2021年9月5-10日, Springer出版社, 2021年, 第414-429页。
414-429页。
- [2] S. Marinai, M. Gori, G. Soda, 用于文档分析与识别的神经网络, IEEE Trans. Pattern Anal. Mach. Intell. 27 (1) (2005) 23-35.
- [3] 张锐、陈杰、杨明, 基于深度学习的绘图顺序恢复, 载于: 2019年第十一届国际先进计算智能会议 (ICACI), IEEE, 2019年, 第129-133页。
- [4] R. Plamondon, S.N. Srihari, 在线与离线手写识别: 综合性综述, IEEE模式分析与机器智能汇刊 22 (1) (2000) 63-84.
- [5] X. Zhang, F. Yin, Y. Zhang, C. Liu, Y. Bengio, 基于循环神经网络的汉字书写与识别, IEEE模式分析与机器智能汇刊 40 (4) (2017) 849-862.
- [6] T. Sumi, B.K. Iwana, H. Hayashi, S. Uchida, 基于交叉变分自编码器的手写模式模态转换, 2019年国际文档分析与识别会议论文集, ICDAR, IEEE, 2019, pp. 407-412.
- [7] W. Swaileh, F. Imbert, Y. Souillard, R. Tavenard, E. Anquetil, 基于时域卷积网络的运动传感器在线手写轨迹重建, 《国际文档分析与识别期刊》(IJ DAR) 26 (3) (2023) 289-302.

- [8] G. Dai, Y. Zhang, Q. Wang, Q. Du, Z. Yu, Z. Liu, S. Huang, 《分离书写者与字符风格实现手生成》, 载于: IEEE/CVF 2023年计算机视觉与模式识别会议论文集, 第5977-5986页。
- [9] 努比格·扎希德, 赫拉拉·穆罕默德, 基于轨迹恢复技术的手写识别综述, 载于: 2017年首届阿拉伯语与波斯语手写体分析与识别国际研讨会论文集, IEEE, 2017年, 第69-73页。
- [10] 肖晓, 金立, 杨勇, 杨伟, 孙杰, 张涛, 构建快速紧凑卷积神经网络实现离线汉字识别, 《模式识别》72卷 (2017年), 第72-81页。
- [11] L. Shen, B. Chen, J. Wei, H. Xu, S.-K. Tang, S. Mirri, 离线中文手写识别面临的挑战: 技术综述, 应用科学 13 (6) (2023) 3500.
- [12] E.-M. Nel, J.A. Du Preez, B.M. Herbst, 基于隐马尔可夫模型估计静态签名笔迹轨迹, IEEE模式分析与机器智能汇刊 27 (11) (2005) 1733-1746.
- [13] R. Senatore, A. Santoro, A. Parziale, A. Marcelli, 生物启发式离线手写轨迹恢复方法, 模因计算 15 (3) (2023) 355-375.
- [14] 徐志, 秦峰, 熊宁, 石浩, 张杰, 林伟, 基于笔画特征与模糊区检测的硬笔楷书骨架提取, 《IET图像处理》(2024)。
- [15] I. Maliki, A. Prayoga, 基于数据增强的卷积神经网络在苏丹语手写识别中的应用, 《工程科学与技术杂志》, 18(2), 2023, 1113-1123.
- [16] G. Boccignone, A. Chianese, L.P. Cordella, A. Marcelli, 《从静态手写中恢复动态运动信息》, 《模式识别》26(3) (1993) 409-418.
- [17] 乔勇, 安原正, 基于双向动态搜索从多笔画图像中恢复书写轨迹, 载于: 第18届国际模式识别会议 (ICPR'06) 论文集第2卷, IEEE出版社, 2006年, 第970-973页。
- [18] 曹志伟, 王玉珍, 一种离线汉字书写顺序重建模型, 《图像与图形学报》10卷 (2009年) 2074-2081页。
- [19] K.K. Lau, P.C. Yuen, Y.Y. Tang, 静态手写图像书写序列恢复的通用书写模型, 《国际模式识别与人工智能杂志》19 (05) (2005) 603-630.
- [20] M. Diaz, G. Crispo, A. Parziale, A. Marcelli, M.A. Ferrer, 复杂长静态手写文本书写顺序恢复, 《交互多媒体与人工智能国际期刊》(2021).
- [21] B. Kovari, 《高效笔画提取方法在手写签名中的应用》, 载于: 第七届应用计算机国际会议论文集, Vol. 7, 2007, pp. 157-161.
- [22] S. Kryzhanovskaya, S. Arseev, L. Mestetskiy, 《基于手写文本图像骨架表示的笔迹重建》, 载于: 第30届计算机图形与机器视觉国际会议论文集 (Graph-iCon 2020)。第2部分, 2020年, <http://dx.doi.org/10.51130/graphicon-2020-2-3-27>, paper27-1。
- [23] T. Wang, C. Liu, 基于全卷积网络的汉字骨架化处理, 收录于: AAAI人工智能会议论文集, 第32卷, 2018年。
- [24] 张瑞、詹永胜、杨明辉, 基于端点顺序预测的手写笔画恢复方法, 计算机科学, 46(S11), (2019) 4。
- [25] H.T. Nguyen, T. Nakamura, C.T. Nguyen, M. Nakawaga, 《基于离线多笔画日语汉字手写的在线轨迹重建》, 载于: 2020年第二十五届国际模式识别会议 (ICPR), IEEE, 2021年, 第8320-8327页。
- [26] A.K. Bhunia, A. Bhowmick, A.K. Bhunia, A. Konwer, P. Banerjee, P.P. Roy, U. Pal, 基于端到端深度编码器-解码器网络的手写轨迹重建, 载于: 2018 第24届国际模式识别会议 (ICPR), IEEE, 2018, 第3639-3644页。
- [27] B. Rabhi, A. Elbaati, Y. Hamdi, A.M. Alimi, 基于端到端系统恢复时间顺序的手写识别, 载于: 2019年国际文档分析与识别会议(ICDAR), IEEE, 2019年, 第 页, 第1231-1236页。
- [28] B. 赵, M. 杨, J. 陶, 基于深度神经网络的手写笔画顺序重建中的笔尖运动预测, 收录于: 2018 第24届国际模式识别会议, ICPR, IEEE, 2018, 第704-709页。
- [29] B. 赵, M. 杨, J. 陶, 《汉字书写笔顺恢复》, 收录于: ICASSP 2019-2019 IEEE国际声学

- [30] 王天强, 刘春林, 基于深度排序预测与启发式搜索的离线多笔画汉字轨迹重建, 载于: 2021 IEEE 国际多媒体大会暨展览会 (ICME), IEEE, 2021年, 第1–6页。
- [31] 陈志, 杨东, 梁杰, 刘晓, 王洋, 彭志, 黄松, 复杂手写轨迹重建: 评估指标与算法, 载于: 亚洲计算机视觉会议论文集, 2022年, 第1060–1076页。

[32] E. Insafutdinov, L. Pishchulin, B. Andres, M. Andriluka, B. Schiele, Deepercut: 更深、更强、更快的多人姿态估计模型, 载于: 《计算机视觉-ECCV 2016: 第14届欧洲会议, 荷兰阿姆斯特丹, , 2016年10月 11-14日, 会议论文集, 第VI 14卷, Springer出版社, 2016年, 第34–50页。

[33] C. Liu, F. Yin, D. Wang, Q. Wang, CASIA在线与离线中文手写数据库, 载于: 2011年文档分析与 识别国际会议论文集, IEEE, 2011年, 第37–41页。

[34] X.-Y. Zhang, F. Yin, Y.-M. Zhang, C.-L. Liu, Y. Bengio, 基于循环神经网络的汉字绘制与识别, IEEE模式分析与机器智能汇刊 40 (4) (2017) 849–862.

[35] 张杰, 杜军, 张帅, 刘东, 胡勇, 胡军, 魏帅, 戴立, 观察、关注与解析: 基于端到端神经网络的手写数学表达式识别方法, 模式识别, 71卷 (2017年), 196–206页。

[36] 尹峰, 王庆峰, 张晓燕, 刘春林, ICDAR 2013中文手写识别竞赛, 载于: 2013第十二届国际文档信息处理与识别会议, IEEE, 2013年, 第1464–1470页。

[37] C. 谢思, 赖青, 廖亮, 金金, 基于新型数据预处理与增强管道的高性能离线中文手写文本识别, 载于: 《文档分析系统: 第14届IAPR国际研讨会, DAS 2020》, 中国武汉, 2020年7月26-29日, 会议论文集14, Springer出版社, 2020年, 第45-59页。

[38] F. Imbert, Y. Soullard, R. Tavenard, E. Anquetil, 基于运动传感器笔迹轨迹重建的领域适应, 收录于: SIFED 2023–法语国家书写与文献国际研讨会, 2023.

朱远平现任天津师范大学教授。他于1999年和2003年先后获得中国长沙中南大学学士和硕士学位。2006年, 他在中国科学院自动化研究所(北京) 获得模式识别与智能系统博士学位。此后, 他在中国科学院(北京) 担任博士后研究员。其研究领域涵盖模式识别、图像处理及人工智能。

李胜楠于2021年获得天津师范大学计算机科学与技术学士学位, 现于该校攻读计算机科学与技术硕士学位。其研究方向涵盖模式识别、图像处理及人工智能领域。

王慧于2019年获得中国山东曲阜师范大学计算机科学学士学位, 现于天津师范大学攻读计算机科学硕士学位。研究方向涵盖模式识别、图像处理及人工智能领域。

魏炜龙于2022年获得天津师范大学计算机科学硕士学位。现就职于中国北京字节跳动公司。研究方向涵盖图像处理、模式识别及人工智能领域。